SAM 2

图像与视频分割



论文精读　Ravi 等　2024

完整论文与附录 · arXiv:2408.00714v2

目录

1 研究问题

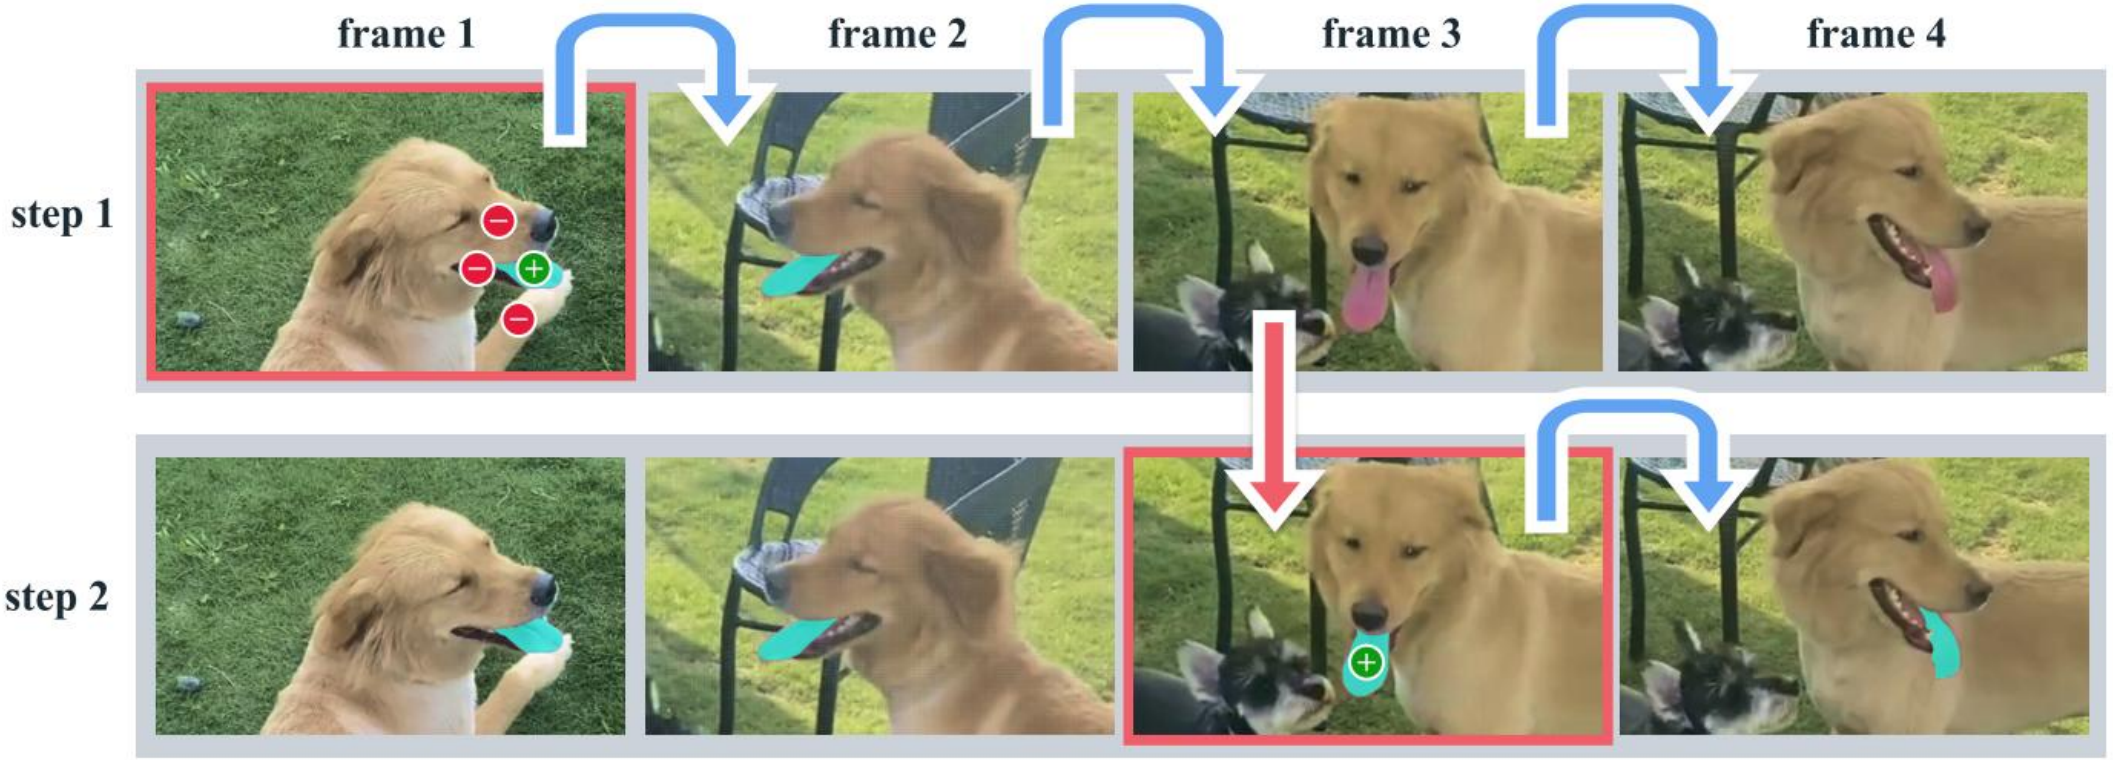
2 模型设计

3 数据构建

4 实验依据

5 局限与复现

视频分割需要连续追踪与纠错

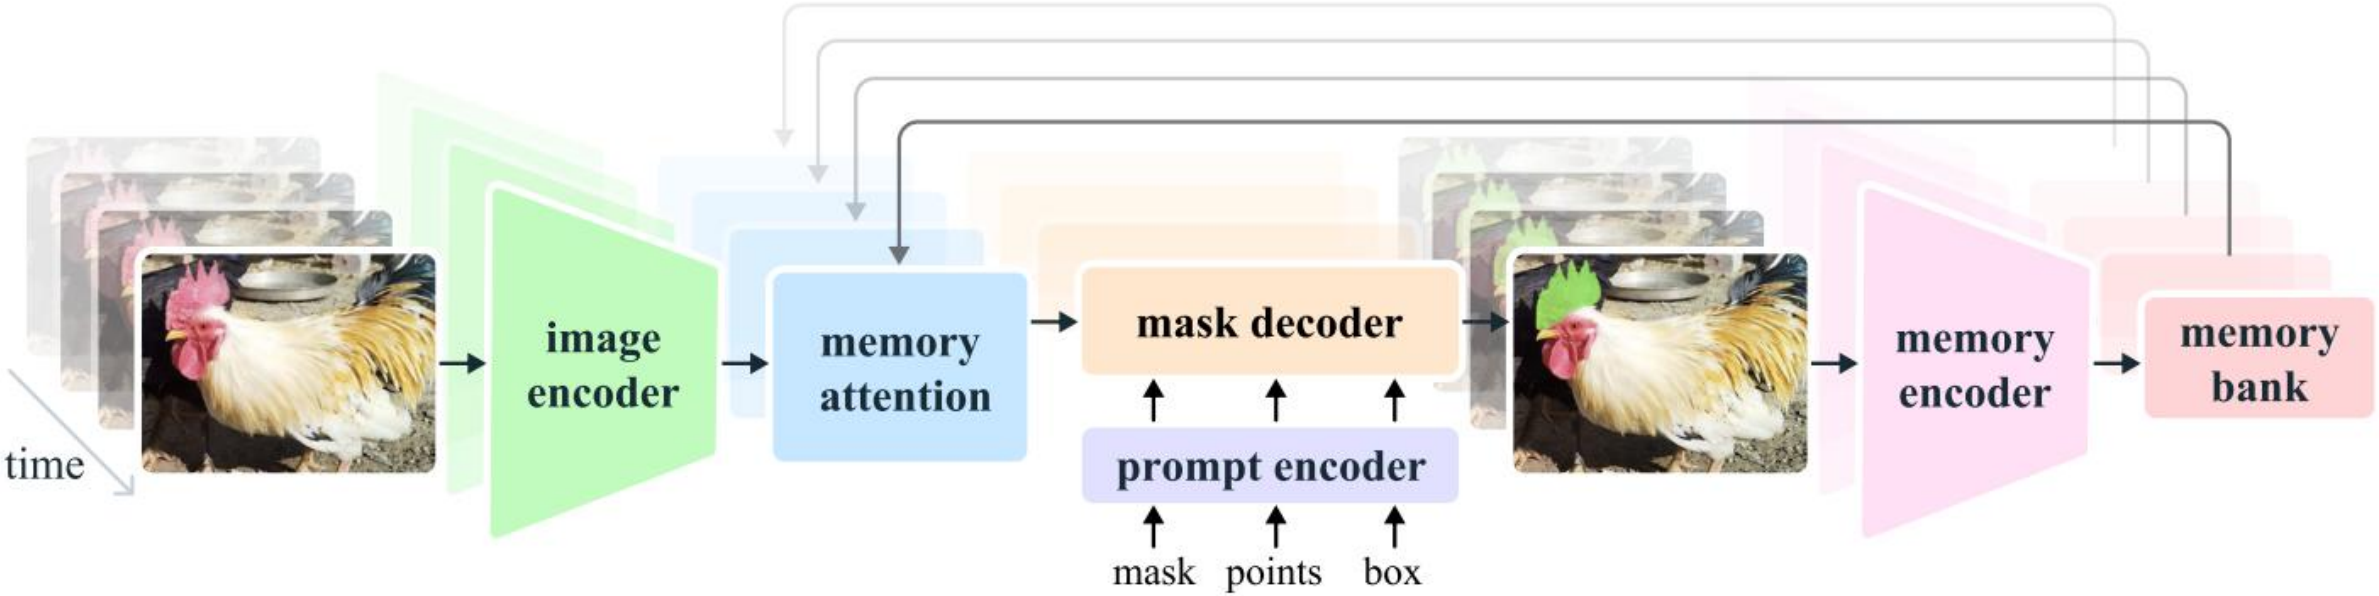


首次选择：正负点指定舌头
自动传播在后续帧丢失目标

补充纠正：第三帧增加正点
利用**已有对象记忆**继续传播

Ravi 等，SAM 2，arXiv v2，2024；Fig.2；§3

记忆参与每一帧预测

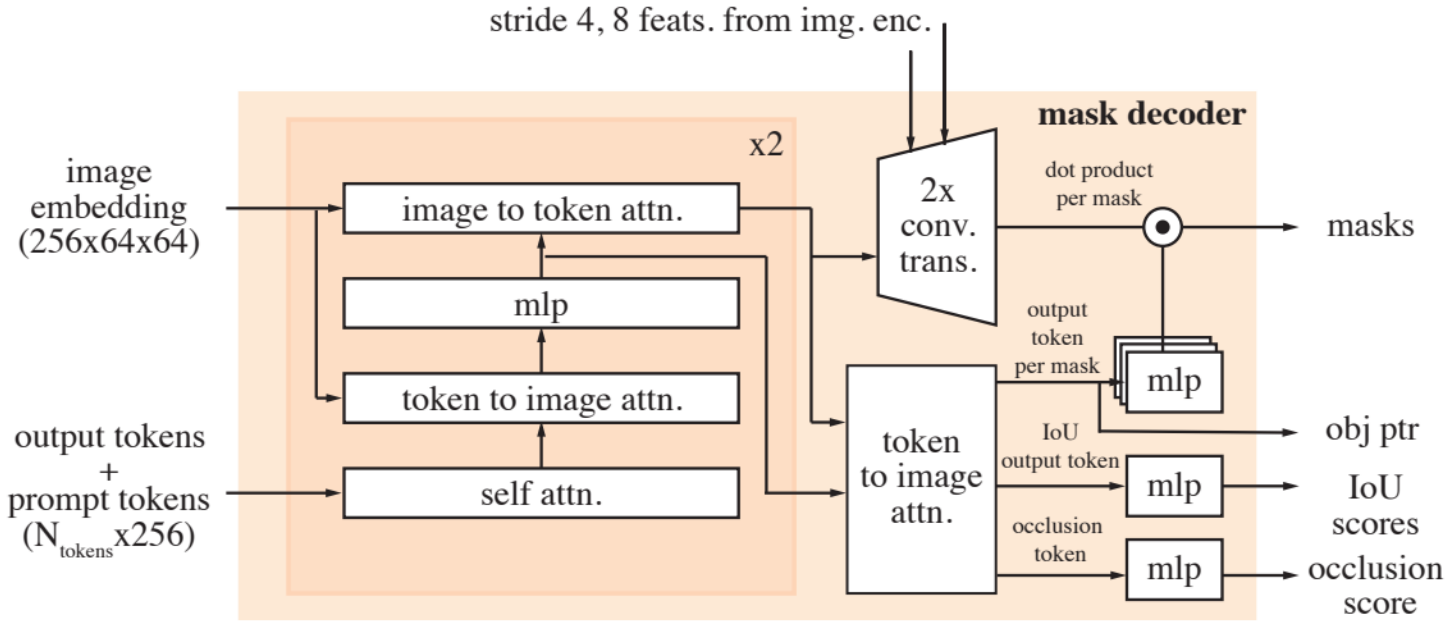


读取**历史记忆**
记忆注意力融合当前帧与对象上下文
新提示仍可修正本帧结果

写入后续帧需要的信息
掩膜与图像特征共同形成记忆
单图任务中记忆为空

Ravi 等，SAM 2，arXiv v2，2024；Fig.3；§4

目标消失时，模型需要判断“看不见”



新增的两个输出

对象指针
用于跨帧保留对象身份线索

遮挡分数
判断对象在当前帧**是否可见**

多候选掩膜
保留对提示范围的不同解释

原图右侧输出：掩膜、**对象指针**、质量与遮挡分数

Ravi 等，SAM 2，arXiv v2，2024；Fig.8；§D.1

对象指针主要改善困难视频

记忆设计	SA-V 验证	LVOSv2 验证	9 个零样本集
无指针、无 GRU	64.5	67.0	70.9
加入 GRU	65.3	68.9	70.5
加入对象指针	**68.3**	**71.6**	70.7

J&F：区域重合与边界质量的平均
数值越大越好
困难集的变化更明显

条件：默认 512 分辨率消融
9 个零样本集平均分并未提高
不能写成“全面提升”

Ravi 等，SAM 2，arXiv v2，2024；Table 11；§A.2.3

训练时模拟用户纠错

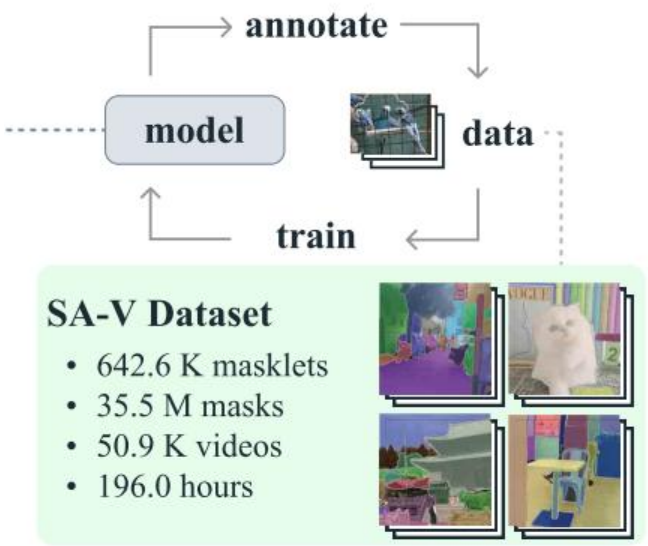
训练环节	输入与提示	学习目的
静态图像预训练	SA-1B 图像与多种提示	保留图像分割能力
图像 / 视频联合训练	8 帧序列，最多 2 帧纠正	利用时间信息接受修正
16 帧微调	困难视频，冻结图像编码器	改善较长序列的预测

初始提示的采样比例
掩膜 50%，正点 25%，框 25%
训练提示由真实标注和预测误差产生

不能把纠正点击理解为自动真值
评估中的模拟点击依赖标注
实际使用中仍由用户指出错误

Ravi 等，SAM 2，arXiv v2，2024；§4；§D.2.2

标注从逐帧重做到局部修正



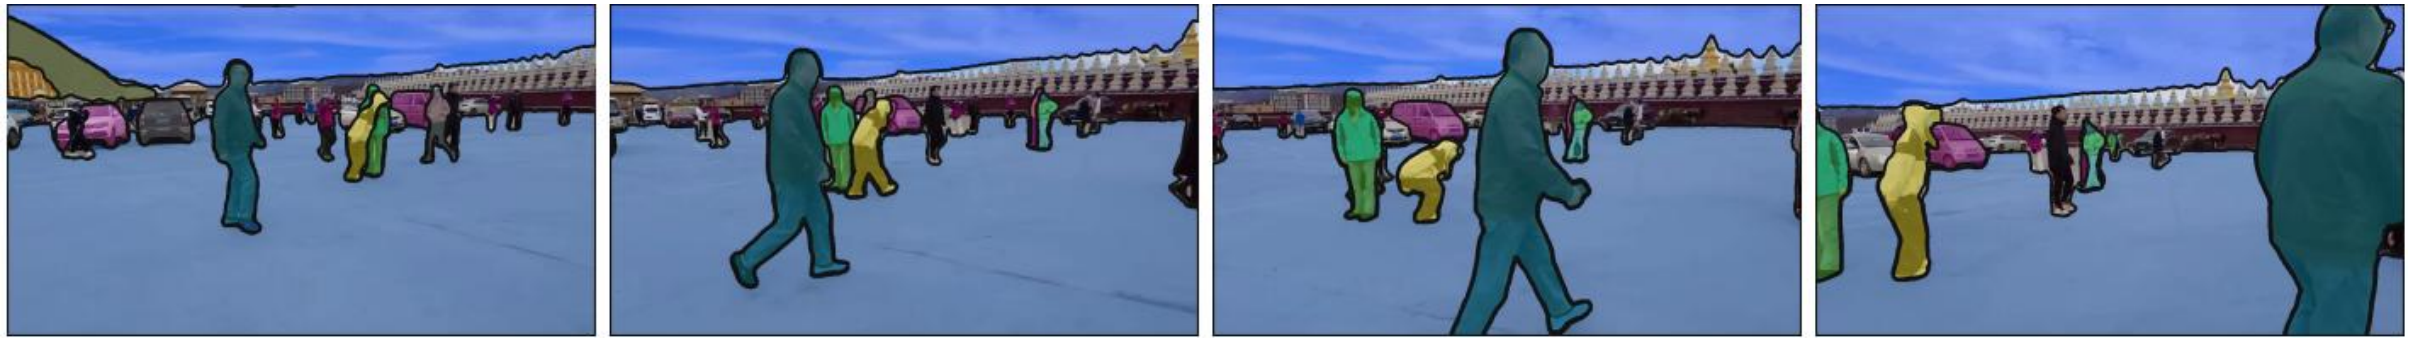
(c) Data: data engine and dataset

标注阶段	主要操作	平均每帧
SAM 逐帧	逐帧标注	**37.8 秒**
掩膜传播	重新标注错误帧	7.4 秒
SAM 2 交互	局部点击修正	**4.5 秒**

相同质量要求下比较人工时间；标注结果仍需独立复核

Ravi 等，SAM 2，arXiv v2，2024；§5.1；Table 1

SA-V 的规模与划分



统计单位	规模	含义
视频	**50.9K**	50,900 段视频
目标轨迹 masklet	**642.6K**	一个目标跨帧的掩膜序列
逐帧掩膜 mask	**35.5M**	同一轨迹贡献多张掩膜

SA-V 验证 / 测试：155 / 150 段视频，293 / 278 条目标轨迹

Ravi 等，SAM 2，arXiv v2，2024；Fig.4；Table 3；§5.2

三种实验，三种提示条件

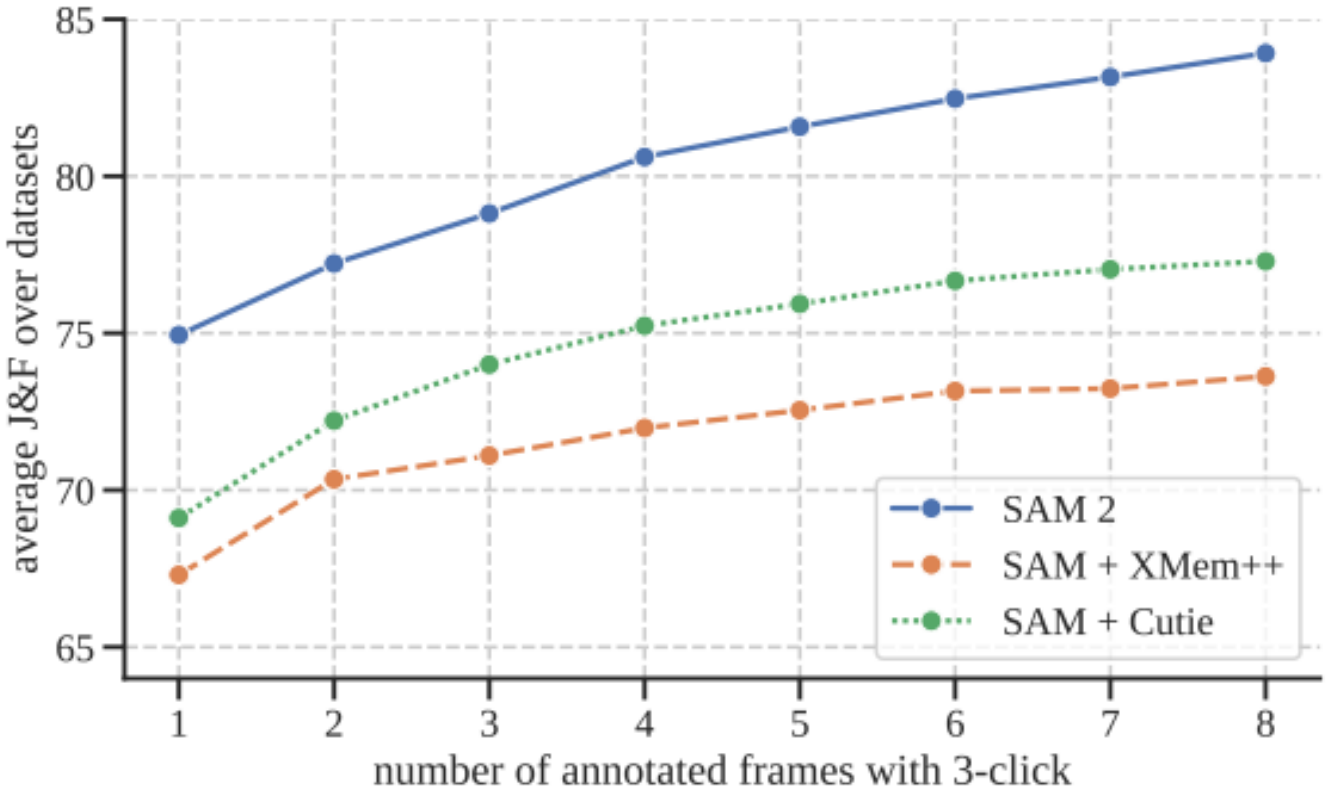
评估任务	提示条件	范围与指标
交互视频 PVS	多帧纠错，每个提示帧 3 次点击	9 个集，平均 **J&F**
首帧视频 VOS	**只在首帧**给点、框或真值掩膜	17 个集，按各集协议汇总
静态图像 SA	1 次或 5 次点击	37 个集，mIoU

J：预测区域与标注区域的重合
F：预测边界与标注边界的匹配
J&F 是二者平均

离线：可回看全片选错误帧
在线：单次向前遍历
二者均为依赖真值的模拟交互

Ravi 等，SAM 2，arXiv v2，2024；§6.1–6.3

较少交互即可获得较高质量



横轴：提示帧数 1–8，**每帧 3 次点击**
纵轴：9 个数据集的平均 J&F，越高越好

Ravi 等，SAM 2，arXiv v2，2024；Fig.5(a)；§6.1

离线交互结果

蓝：SAM 2
橙：SAM + XMem++
绿：SAM + Cutie

允许回看全片选择错误帧
提示帧越多，交互成本越高

原文另有在线设置，趋势一致

只给首帧提示，优势仍然存在

方法	首帧 1 点	首帧 3 点	首帧真值掩膜
SAM + XMem++	56.9	68.4	72.7
SAM + Cutie	56.7	70.1	74.1
SAM 2	**64.7**	**75.3**	**79.3**

比较方法时，沿同一列读
提示条件完全一致才有意义
三点提示下对 Cutie 组合高 5.2 分

17 个数据集采用各自评估协议
通常为 J&F，VOST 使用 J
真值掩膜基线直接输入跟踪器

Ravi 等，SAM 2，arXiv v2，2024；Table 4，三列摘录

图像任务的精度与速度

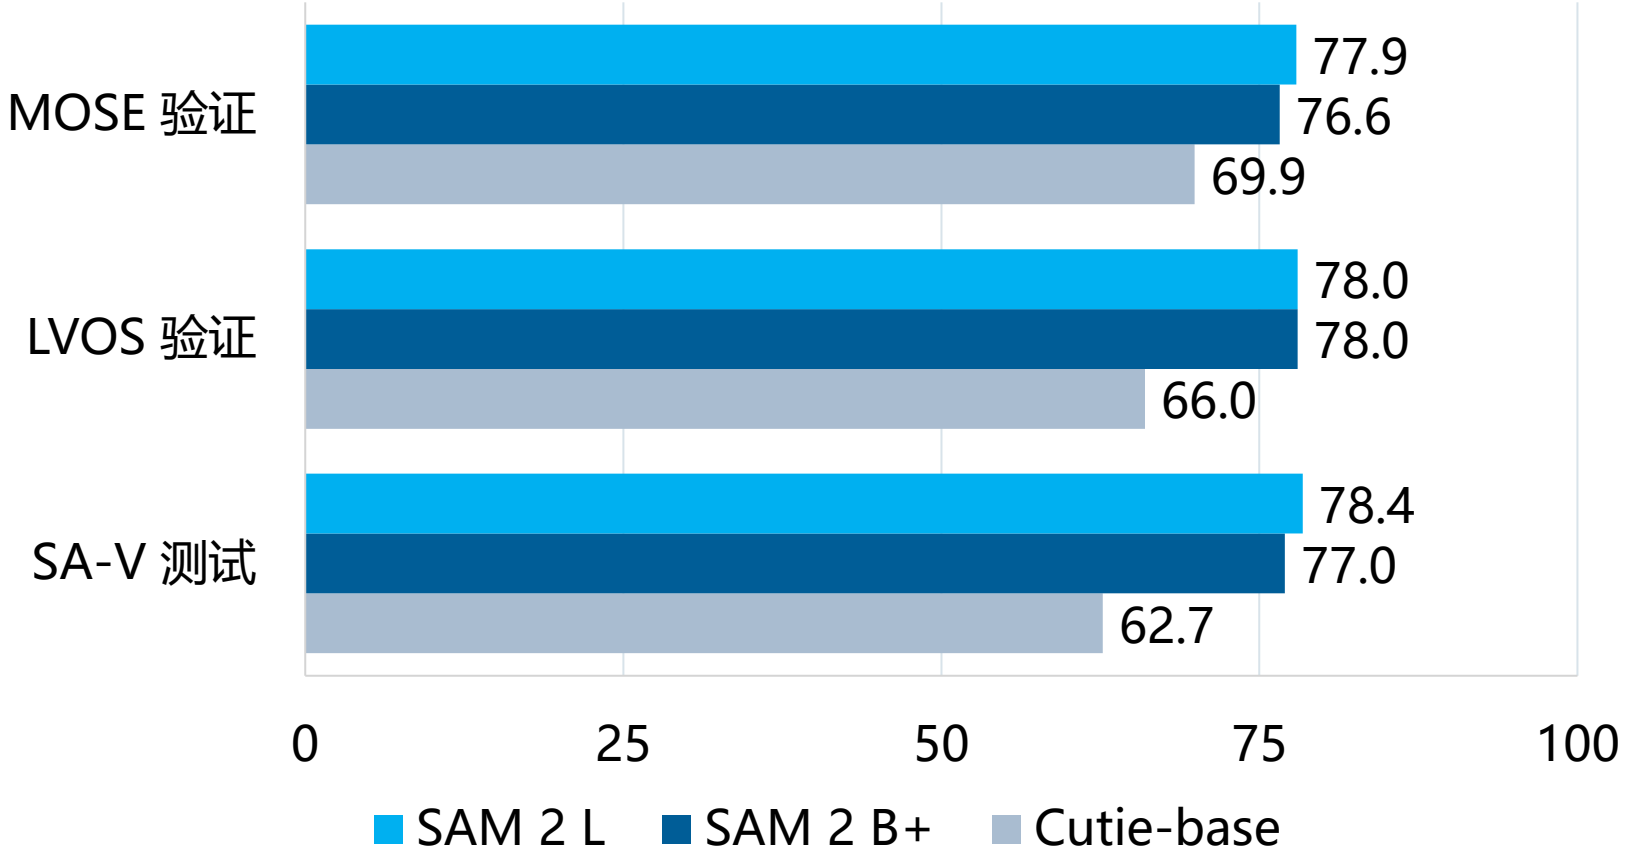
模型与训练数据	SA-23 单点 mIoU	单图 FPS
SAM，SA-1B	58.1	21.7
SAM 2，SA-1B	58.9	**130.1**
SAM 2，混合数据	**61.9**	**130.1**

相同 SA-1B 数据下
130.1 / 21.7 ≈ 6.0 倍
速度条件：单张 A100 GPU

原文数值冲突
§6.3 正文写 61.4，表 5 为 **61.9**
本页按表格值列示，待作者澄清

Ravi 等，SAM 2，arXiv v2，2024；Table 5；§6.3

困难集与长视频的结果



首帧真值掩膜

指标：J&F，越大越好
三组数据分别对应
遮挡、长视频与开放目标

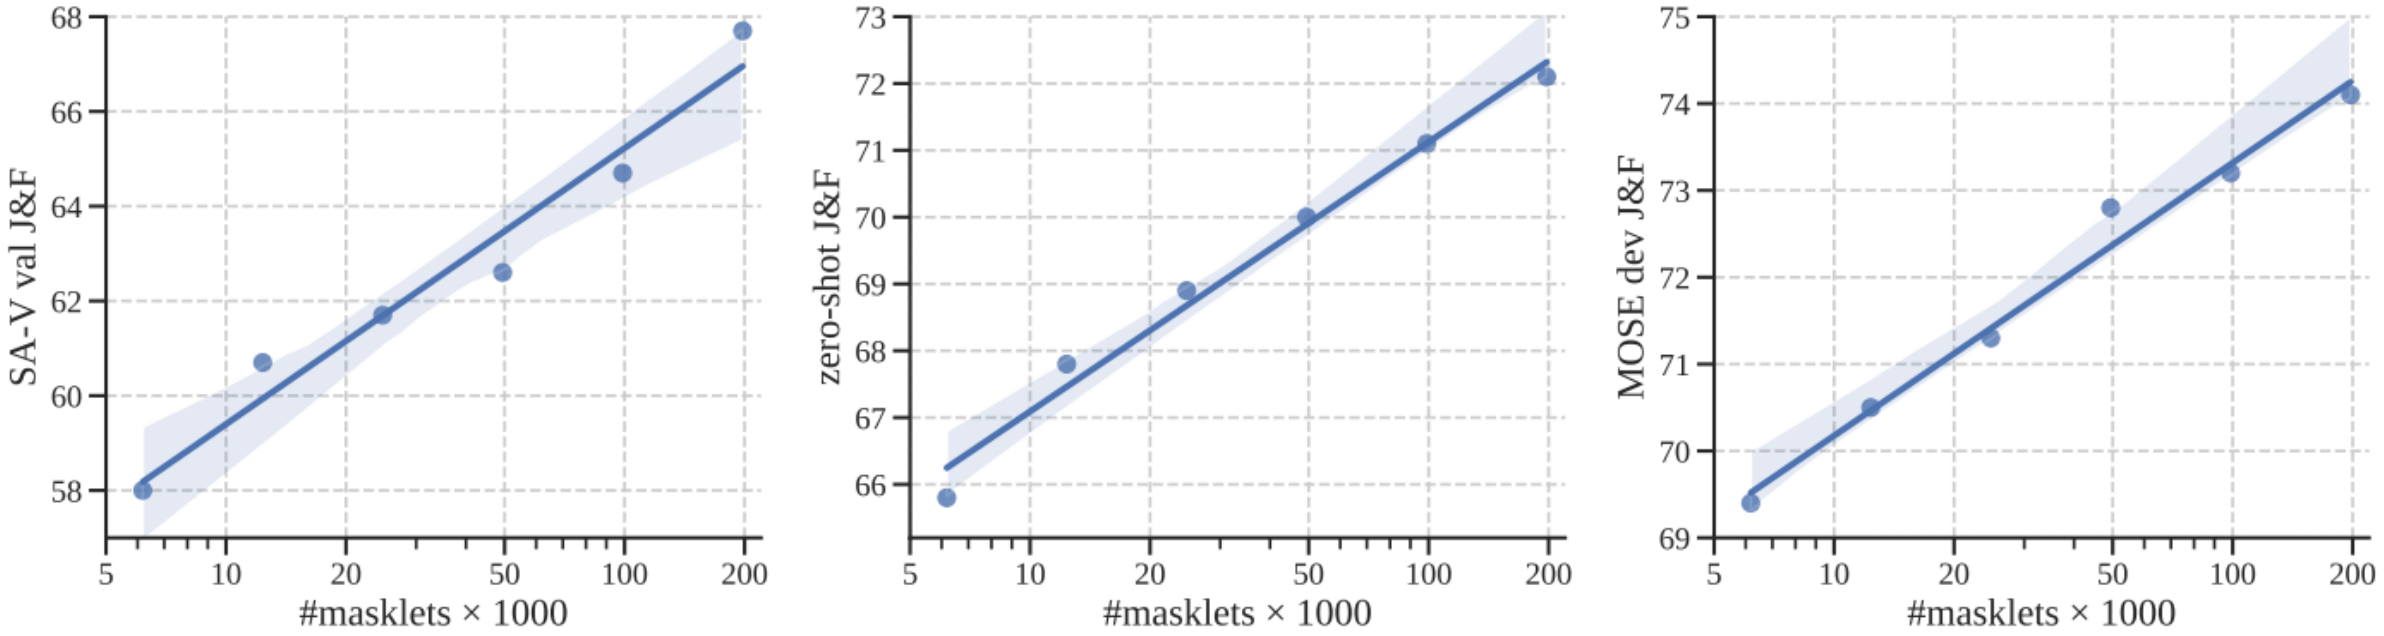
速度与精度一起看

B+：43.8 FPS
L：30.2 FPS

单卡 A100，批量 1
这是视频速度

Ravi 等，SAM 2，arXiv v2，2024；Table 6，三列摘录；§7

更多数据带来持续收益



左：SA-V 验证；中：9 个零样本集
右：MOSE 开发集
横轴为轨迹数量，采用**对数刻度**

统一条件：首帧 3 次点击
不同子图的纵轴范围不同
比较各自趋势，不按线条角度比增速

Ravi 等，SAM 2，arXiv v2，2024；Fig.6；§A.1

困难样本有价值，但不能替代全部数据

训练轨迹	SA-V 验证	9 个零样本集	SA-23 图像
随机 50K	63.7	68.7	59.1
修正最多的 50K	**66.2**	69.2	58.6
完整约 190K	**69.9**	70.8	59.8

前两列为视频 J&F
最后一列为图像单点 mIoU
每一列内进行同条件比较

困难样本改善视频学习效率
完整数据仍然更好
未支持“少量样本全面替代”

Ravi 等，SAM 2，arXiv v2，2024；Table 8；§A.1

记忆容量需要折中

记忆上限	SA-V J&F	9 集 J&F	相对吞吐
4	68.6	70.5	1.01×
6	68.3	70.7	1.00×
8	69.0	70.7	**0.93×**

三种记忆容量在同一消融设置下比较

默认保留 6 个历史帧

更多记忆不保证单调提升
还需要保存有提示帧的信息

输入分辨率：512
速度按默认设置归一化
0.93× 表示吞吐降低

Ravi 等，SAM 2，arXiv v2，2024；Table 9(c)；§A.2.1

遮挡、相似对象与镜头切换仍然困难



论文报告的困难
长时间遮挡、相似对象、镜头切换
细小且快速运动的结构

多对象处理的边界
共享图像特征，分别预测各对象
对象之间**没有显式交流**

Ravi 等，SAM 2 v2；图为场景例，非失败截图；局限见 §C

公开权重与论文主表要分开核对

核对项目	论文中需要区分的设置
版本	v2 的结果对应 **SAM 2.1**
主实验数据	完整数据组合，可能包含额外公开 VOS 数据
公开权重训练	SA-V 人工标注 + Internal + SA-1B
复现记录	检查点、数据划分、提示、分辨率、硬件

Internal 是作者使用的内部许可视频数据
复现需先确认能获得的数据与对应检查点

Ravi 等，SAM 2，arXiv v2，2024；p.2 脚注；§6；§D.2.2

哪些结论已被证据支持

研究问题	关键证据	可执行的下一步
能否减少重复交互	Fig.5：同等交互下质量更高	固定提示预算比较
记忆与数据是否有用	Tables 8、11：收益有条件	分别分析困难集与平均值
真实任务是否可靠	§C：遮挡和相似对象仍困难	建立失败场景分层测试

先复现同一检查点与**相同提示协议**
记录质量、交互次数与实际耗时
再讨论改进是否来自方法本身

来源：完整论文及相关附录
展示内容为作者实验与论文分析
尚未产生本地复现实验结果

Ravi 等，SAM 2，arXiv v2，2024；Fig.5；Tables 4、8、11；§C

谢谢大家